

Когда разреженность скрывает исполнительный механизм: предварительно зарегистрированное экономическое сопоставительное исследование SINDy-MPC для управления микроклиматом теплицы

Автор Первый^a, Автор Второй^a

^aОрганизация, кафедра, Город, Страна

Abstract

Интерпретируемые суррогатные модели, восстановленные из данных, — в частности, разреженная идентификация нелинейной динамики (SINDy), — привлекательны для модельно-прогнозирующего управления (МПУ) микроклиматом теплицы, поскольку дают явные, поддающиеся проверке уравнения, а не «чёрный ящик». Однако цену такой интерпретируемости редко измеряют при честном протоколе: эталоны сравнения не настроены, метрикой служит косвенный показатель слежения, а не прибыль, и — что наименее очевидно — рецепт идентификации выбирают по качеству прогноза в разомкнутом контуре. В работе приводится предварительно зарегистрированное вычислительное экономическое сопоставительное исследование десяти регуляторов на имитационной модели томатной теплицы GreenLight (Постов-на-Дону, реальная погода ERA5 2018–2023). Первичной метрикой служит собственный экономический показатель эффективности симулятора (EPI, сезонная прибыль), первичным критерием — двухосевое доминирование по Парето (EPI против числа нарушений ограничений), на 20 независимых повторях с парной непараметрической статистикой. Предварительно зарегистрированный рецепт SINDy-MPC, замороженный по разомкнутым метрикам до какой-либо оценки в замкнутом контуре, экономически оказывается среди слабейших интерпретируемых регуляторов (1,18 против 4,63 EUR/м² у настроенного эталона на правилах). Однопараметрическая абляция вскрывает причину: порог разреженности обнуляет член котла в уравнении температуры — единственный смоделированный орган нагрева, — и EPI в замкнутом контуре обрушивается с 3,8 до 1,0 EUR/м², тогда как ошибка многошагового прогноза в разомкнутом контуре остаётся почти неизменной (2,25 → 2,39). Тем самым критерий отбора по разомкнутому контуру нечувствителен к тому провалу замкнутого контура, который он порождает. Восстановление члена — более плотным порогом либо методом DAGger — возвращает EPI к паритету с эвристикой без потери интерпретируемости, а восстановленная модель совпадает с первопринципной моделью «серого ящика». Сравнение с дополнительными регуляторами исключает очевидные альтернативные объяснения: оракул по истинной модели перерасходует ресурсы и не является верхней границей; нормированный PPO улучшается, но не выигрывает; нейросетевое МПУ — худшее. Следовательно, узким местом не являются ни недостаточная точность модели, ни интерпретируемость. Доказуемая ценность интерпретируемой суррогатной модели лежит не в экономическом превосходстве, а в безопасности и защите при выходе за пределы обучающего распределения. Сделан вывод: экономность модели не тождественна её интерпретируемости; разреженность недопустимо включать в критерии отбора модели, когда конечной задачей является управление в замкнутом контуре; предрегистрация, замороженная по разомкнутому контуру, способна систематически удостоверявать катастрофичную для управления модель.

Keywords: управление микроклиматом теплицы, модельно-прогнозирующее управление, разреженная идентификация нелинейной динамики, интерпретируемое машинное обучение, идентификация для целей управления, экономическое сопоставительное исследование

1. Введение

Тепличное овощеводство — энергоёмкая отрасль, где решения по управлению климатом прямо переходят в прибыль: нагрев, подкормка CO_2 и досветка составляют основную долю переменных затрат, и их приходится балансировать против выручки от прироста урожая. Модельно-прогнозирующее управление (МПУ) здесь естественно, поскольку оно оптимизирует целевую функцию на конечном горизонте при ограничениях на температуру, влажность и CO_2 , задающих продуктивный климат [1, 2, 3]. Однако МПУ нуждается в модели, а первопринципные модели теплицы трудоёмки в построении и калибровке. Это мотивирует суррогатные модели, восстанавливаемые из данных, и в частности SINDy — разреженную идентификацию нелинейной динамики, которая восстанавливает явные уравнения движения как разреженную комбинацию базисных функций [4, 5, 6]. В отличие от нейросетевых суррогатов, модель SINDy — «белый ящик»: её уравнения можно прочесть, проверить на физическую и размерную согласованность и аналитически встроить в решатель МПУ. Для агронома или сертифицирующего органа такая интерпретируемость — не роскошь, а практическое требование доверия и отладки.

Центральный вопрос состоит в том, платят ли за интерпретируемость качеством: занимает ли интерпретируемое SINDy-MPC недоминируемую (парето-конкурентоспособную) позицию относительно «чёрных ящиков» или несёт измеримую «цену прозрачности». Честный ответ затрудняют три систематических изъяна самой процедуры сравнения, распространённые в литературе по управлению теплицами и по управлению из данных. Обученные регуляторы нередко сопоставляют с заведомо слабой эвристикой, тогда как хорошо настроенные агрономические правила оказываются сильным конкурентом; в качестве метрики берут ошибку слежения за уставкой вместо экономической прибыли, хотя эти величины не связаны монотонно; наконец — и это наименее очевидно — гиперпараметры суррогата выбирают по точности прогноза в разомкнутом контуре, молчаливо полагая, что более точная модель даёт лучшее управление. Именно против последнего допущения три десятилетия предостерегает идентификация для целей управления [7, 8], и именно его для обученной динамики заново установило «рассогласование целевых функций» (objective mismatch) [9, 10].

Все три изъяна устраняются проведением предварительно зарегистрированного вычислительного экономического сопоставительного исследования. Первичной метрикой служит собственный экономический показатель эффективности симулятора (ЕРІ) — сезонная прибыль, считываемая прямо из модели вознаграждения, а не косвенный показатель. Поскольку ЕРІ не штрафует нарушения ограничений, первичным сравнением является двухосевое доминирование по Парето (ЕРІ против нарушений). Эталоны включают настроенный регулятор на правилах и честно реализованные регуляторы обучения с подкреплением при равном бюджете гиперпараметров. Рецепт идентификации замораживается по разомкнутым метрикам и метрикам прозрачности до какой-либо оценки в замкнутом контуре, следуя практике предварительной регистрации [11], чтобы выбор рецепта не загрязнял честное сравнение. Оцениваются десять регуляторов на 20 повторях с парной непараметрической статистикой [12, 13, 14].

Предварительно зарегистрированная гипотеза — что SINDy-MPC недоминируемо при малой цене прозрачности — не подтверждается. Ценность исследования, однако, не в отрицательном результате, а в вскрытом механизме: сравнение с дополнительными регуляторами изолирует причину недобора предрегистрированного интерпретируемого регулятора, и эта причина конкретна и переносима на другие задачи.

Основной методологический результат работы — установленный механизм. Порог разреженности STLSQ удаляет из модели контроль-критичный член исполнительного механизма (котла), и экономический показатель в замкнутом контуре причинно следует за наличием этого члена, тогда как ошибка прогноза в разомкнутом контуре к его исчезновению почти нечувствительна. Как следствие, процедура отбора рецепта, замороженная по разомкнутому контуру ради защиты от цикличности вывода, систематически удостоверяет модель, катастрофичную для управления, — в чём и состоит ловушка предрегистрации. Эти наблюдения опираются на честное экономическое сопоставление на валидированной агрономической модели, где показатель ЕРІ поэлементно поверен против функции вознаграждения симулятора, эталон на правилах настроен, бюджет гиперпараметров одинаков для всех методов, а выводы подкреплены парной статистикой на двадцати повторях, — чего не доставало прежним тепличным сравнениям, ограниченным обучением с подкреплением [15]. Наконец, работа переосмысливает саму ценность интерпретируемости: она проявляется в прозрачности модели, в безопасности и в способности распознавать выход за пределы обучающего

распределения, а не в экономическом превосходстве, — и экономность описания не следует смешивать с интерпретируемостью.

2. Обзор литературы

Оптимальное и прогнозирующее управление климатом теплицы простирается от постановки оптимального управления связанной системой «климат–растение» у ван Хентена [1, 16], через современные реализации МПУ [3, 17], до стохастического оптимального управления при погодной неопределённости [18]. Обучение с подкреплением (ОП) сравнивали с МПУ с неоднозначным экономическим итогом: ОП может повышать продукцию, но часто при худшей рентабельности [19, 20, 21]. Использованный здесь симулятор — GreenLight [22, 23], обёрнутый интерфейсом GreenLight-Gym [15]. Однако это *среда* для ОП: она даёт быстрый дифференцируемый симулятор и сравнивает алгоритмы ОП, но не проводит честного экономического сравнения регуляторов с настроенным эталоном на правилах и не рассматривает ни интерпретируемые суррогаты на разреженной идентификации, ни вопрос об отборе по разомкнутому либо замкнутому контуру. Настоящая работа занимает этот пробел.

SINDy восстанавливает экономные уравнения движения разреженной регрессией по библиотеке базисных функций [4], обобщается на объекты с управлением [5] и естественно сочетается с МПУ в условиях дефицита данных [6]. Устойчивость повышают ансамблированием [24], релаксированной и ограниченной оптимизацией [25] и зрелым инструментарием [26, 27]. Базовый метод последовательного порогового наименьших квадратов (STLSQ), однако, чувствителен к порогу разреженности: слишком большой порог удаляет физически важные члены с малыми коэффициентами, ухудшая динамику [28, 29]; на это прямо нацелены новейшие оптимизаторы [30]. Прежние работы трактуют это как патологию *идентификации* и предлагают лучшие *оптимизаторы*; здесь же её следствие диагностируется внутри экономического контура МПУ, с установленной причинной связью с прибылью, и показывается, что штатный протокол отбора по разомкнутому контуру прямо в неё попадает.

То, что точность прогноза в разомкнутом контуре — плохой косвенный показатель качества управления в замкнутом, является фундаментальным положением идентификации для целей управления: арбитром качества модели служит контур, а не подгонка [7, 31, 8, 32]. Для обученной динамики это же явление заострили как «рассогласование целевых функций»: правдоподобие одношагового прогноза не коррелирует с качеством управления [9, 33], — с сопутствующими средствами в отборе, ориентированном на ценность и на управление [34, 35]. Вклад настоящей работы — не общий принцип и не новое средство, а его конкретный, интерпретируемый и причинно проверенный пример: поскольку суррогат является «белым ящиком», провал читается почленно (единственный удалённый исполнительный механизм), а не диагностируется перевзвешиванием «чёрного ящика». Для восстановления члена применяется итеративная агрегация наборов данных (DAgger) [36] — устоявшийся мост между экспертом-МПУ и обучаемой моделью [37, 38, 39].

3. Методы

Первичная метрика. Все регуляторы оцениваются по собственной экономике симулятора, а не по косвенному показателю. На каждом шаге модель вознаграждения GreenLight возвращает прибыль $\pi_k = g_k - c_k$, где выигрыш $g_k = (x_k^{\text{fruit}} - x_{k-1}^{\text{fruit}}) \cdot 10^{-6} / \text{dmfm} \cdot p_{\text{fruit}}$ — выручка от прироста сухой массы плода (переводимой в сырую массу через коэффициент $\text{dmfm} = 0,065$ и оцениваемой по $p_{\text{fruit}} = 1,6 \text{ EUR/kg}$), а переменные затраты c_k суммируют нагрев, досветку и подкормку CO_2 по ценам 0,09, 0,30 и 0,30 EUR за кВт·ч, кВт·ч и кг соответственно. Сезонный показатель — $\text{EPI} = \sum_k \pi_k [\text{EUR/m}^2]$. Поэлементно поверено, что пошаговая экономика, используемая каждым регулятором (и оракулом, см. ниже), тождественна функции вознаграждения симулятора, так что EPI — истинная целевая величина, а не приближение. Поскольку EPI не включает штрафы за нарушения и регулятор может повышать его, чаще выходя за продуктивные коридоры ($\text{CO}_2 \in [300, 1600] \text{ ppm}$, $T \in [15, 34] \text{ }^\circ\text{C}$, $\text{RH} \in [50, 85]\%$), первичным сравнением служит двухосевой критерий Парето — EPI против сезонного числа шагов с нарушениями — с указанием недоминируемого фронта (рис. 1). Вторичным размерно-согласованным скаляром тяжести служит scaled_pen — площадь нарушения

Таблица 1: Регуляторы и роль каждого из них в исследовании. Набор подобран так, чтобы последовательно отвергать альтернативные объяснения недобора предрегистрированного интерпретируемого метода.

Регулятор	Класс	Проверяемое альтернативное объяснение	Ответ по данным
На правилах	настроенная эвристика	наличие сильной простой цели (и эксперт DAgger)	да — EPI 4,63, планка
МПУ «серого ящика»	редуцированная физика	слабость самих МПУ и библиотеки	нет — 3,79 работает; причина в пороге
SINDy-MPC (подтверждающий)	предлагаемый, предрег.	исследуемый метод	провал: 1,18 (котёл выпал)
SINDy-MPC (плотный/+DAgger)	предлагаемый, починенный	устранимость дефекта без потери интерпретируемости	да — 3,8–5,2, всё ещё «белый ящик»
Оракул (3 ч, СЕМ)	МПУ по истинной модели	недостаток точности модели	нет — 1,99, перерасход
NN-MPC	«чёрный ящик»-суррогат	преимущество «чёрного ящика»	нет — −5,09, худший
PPO / SAC	«чёрный ящик»-ОП	интерпретируемость как узкое место	нет — оба ниже эвристики

по каждому ограничению, нормированная по шкале самого симулятора. Единый «EPI со штрафом в евро» не вводится, поскольку симулятор не оценивает нарушения в деньгах.

Симулятор, локация и данные. Эксперименты используют модель томатной теплицы GreenLight [22] через интерфейс GreenLight-Gym [15]. Локация — Ростов-на-Дону (47,24° с. ш., 39,71° в. д.); реальная погода за 2018–2023 гг. взята из ERA5/ERA5-Land через Open-Meteo, с производными членами (температура неба, почвы). Сезон — 60 суток с началом 1 марта, шаг управления 15 минут. Применяется разбиение по годам без утечки: обучение на 2018–2019, тест в пределах обучающего распределения на 2020, а 2021–2023 отложены как выход за пределы распределения (OOD). Данные для идентификации собираются регулятором на правилах с наложением псевдослучайного двоичного сигнала возбуждения (ПСДП, амплитуда 0,3) на исполнительные механизмы, при контроле числа обусловленности регрессии.

Регуляторы. Сравниваются десять регуляторов пяти семейств (таблица 1): настроенный регулятор на правилах (агрономическая эвристика — нижний эталон и эксперт для DAgger); предлагаемое SINDy-MPC в четырёх вариантах — предрегистрированный подтверждающий рецепт, плотный рецепт с сохранением котла и их версии, дообученные методом DAgger; редуцированное первопринципное МПУ «серого ящика» на том же решателе; нейросетевое МПУ (NN-MPC, суррогат 64×64); две стратегии обучения с подкреплением, PPO [40] и SAC [41], через Stable-Baselines3 [42]; и оракул-МПУ, планирующий по истинной динамике симулятора. Все обучаемые регуляторы получают равный бюджет гиперпараметров (16 попыток). ОП обучается на 2×10^5 шагов среды с нормировкой наблюдений и вознаграждения (VecNormalize), пропуск которой сильно искажает результат ОП.

Конвейер и предварительная регистрация. Предлагаемый метод проходит четыре стадии. Сначала регулятор на правилах с наложенным ПСДП собирает данные; затем разреженная регрессия восстанавливает интерпретируемое дискретное одношаговое отображение $x_{k+1} = \Xi \Theta(x_k, u_k, d_k)$ степени 1, пригодной для аналитического встраивания в МПУ; полученный суррогат встраивается в решатель CasADi/do-mpc, который оптимизирует согласованную с EPI цель при климатических ограничениях на конечном горизонте; при необходимости добавляется онлайн-адаптация (DAgger или EKF-SINDy) с монитором OOD и безопасным откатом. Рецепт идентификации (сглаживание, оптимизатор и библиотека) не задаётся заранее: он выбирается в абляции (E2) и затем замораживается по разомкнутым метрикам идентификации (устойчивость многошагового прогноза, встраиваемость в МПУ, прозрачность) до и независимо от какого-либо EPI в замкнутом контуре на отложенном тестовом сезоне; такая предрегистрация защищает от цикличности вывода. Замороженный подтверждающий рецепт использует библиотеку physics_no_cross, степень 1 и ансамблевый оптимизатор; выбранный по замкнутому контуру разведочный рецепт хранится отдельно и приводится лишь как апостериорная чувствительность. Идентичный замороженный рецепт загружается

каждым последующим экспериментом из единого источника истины.

Критерии допуска и статистика. Модель допускается к сравнению, только если проходит критерий прозрачности (явные уравнения «белого ящика», доля пройденных проверок знаков и размерностей выше порога, структурная устойчивость набора активных членов при бутстрепе) и критерий встраиваемости в МПУ. Оба критерия намеренно разомкнутые; их последствия рассматриваются ниже. Источником дисперсии служит пересбор обучающих данных на каждом повторе: каждый повтор заново собирает набор для идентификации и переобучает суррогат, так что модели на разных повторях действительно различаются. Используются 20 повторов для всех регуляторов; SAC сошёл лишь на 10 из 20 и приводится по ним. Парные сравнения проводятся критерием знаковых рангов Уилкоксона с попарностью по повтору [12] и поправкой Холма [13], с указанием размера эффекта (d Коэна) и доверительных интервалов бутстреп [14, 43].

Оракул. Оракул — регулятор на скользящем горизонте по методу кросс-энтропии (СЕМ), планирующий прямо по истинному интегратору симулятора (48 выборочных последовательностей действий, горизонт 3 часа, две итерации уточнения, «тёплый старт» от действия правил), с той же экономической целью, что и у МПУ. Разрыв между ним и суррогатным МПУ изолирует влияние точности модели. Верхней границей сезонного EPI оракул при этом не является: короткий скользящий горизонт жадно максимизирует краткосрочную прибыль, а выборочный оптимизатор деградирует на длинных горизонтах, поэтому оракул трактуется как контроль точности модели, а не как потолок.

4. Результаты

Десять регуляторов подобраны так, чтобы изолировать причину недобора предрегистрированного интерпретируемого регулятора, последовательно отвергая очевидные альтернативные объяснения (слабый МПУ, недостаточная точность модели, преимущество «чёрного ящика»). Вердикты по предрегистрированным гипотезам сведены в таблице 2.

Абляция E2 по сглаживанию, оптимизатору, библиотеке и степени (42 рецепта) выбрала — по устойчивости многошагового прогноза и критериям прозрачности и встраиваемости — рецепт с библиотекой `physics_no_cross`, степенью 1 и ансамблевым оптимизатором как подтверждающий, замороженный до какой-либо оценки в замкнутом контуре. Расхождение многошагового прогноза для этого рецепта пренебрежимо (доля расходящихся траекторий ≈ 0 при бюджете ≥ 3 суток), так что он проходит разомкнутую планку, на которую опирается предрегистрация. Гипотеза G2 (существование рецепта с устойчивым прогнозом) тем самым выполнена, однако, как показано ниже, устойчивости в разомкнутом контуре необходимо, но недостаточно.

Таблица 3 приводит EPI, нарушения и тяжесть в замкнутом контуре на 20 повторях для всех десяти регуляторов с парной значимостью против эталона на правилах; рисунок 1 показывает плоскость Парето «EPI-нарушения». Вершины достигает лишь восстановленное методом DAgger SINDy-MPC: $5,23 \pm 2,40$ EUR/m², статистически неотлично от 4,63 у правил ($\Delta = +0,59$, $p_{\text{Holm}} = 0,26$). Все остальные регуляторы значимо хуже настроенной эвристики: МПУ «серого ящика» (3,79, $p_{\text{Holm}} = 0,017$), PPO (3,36, $p_{\text{Holm}} = 0,001$), предрегистрированное подтверждающее SINDy-MPC (1,18, $p_{\text{Holm}} = 0,009$), SAC (−2,41) и NN-MPC (−5,09, $p_{\text{Holm}} \approx 2 \times 10^{-5}$). Недоминируемый фронт образуют восстановленное DAgger SINDy-MPC, эвристика на правилах, PPO и — как вырожденный угол минимума нарушений с отрицательным EPI — SAC. По оси тяжести восстановленное DAgger SINDy-MPC накапливает даже меньшую суммарную тяжесть нарушений, чем правила (426 против 485), несмотря на большее число шагов с нарушениями; поэтому обе оси приводятся совместно. Таким образом, центральная предрегистрированная гипотеза не подтверждена, и единственный интерпретируемый регулятор, дотягивающий до эвристики, достигает этого ценой починки, механизм которой рассматривается далее.

Механизм: разреженность скрывает исполнительный механизм. Предрегистрированный подтверждающий рецепт экономически слабейший среди интерпретируемых регуляторов ($1,18 \pm 4,33$, против 4,63 у правил и 3,79 у МПУ «серого ящика», делящего с ним решатель и библиотеку). При этом рецепт отбился не за плохое управление в замкнутом контуре: он был заморожен, до какой-либо замкнутой оценки, как наиболее экономная модель, прошедшая разомкнутые критерии и критерий прозрачности. Тем самым рецепт, который предрегистрация удостоверяла как оптимальный по идентификации, оказывается рецептом, проваливающимся в контуре.

Таблица 2: Сводка по гипотезам (предрегистрированные Г1–Г4, вердикты на 20 повторях).

Гипотеза	Вердикт	Обоснование
Центральная	не подтверждена	conf+DAgger — ничья с правилами ($p=0,26$)
Г1 (разрыв до оракула)	не выполнена	оракул $1,99 <$ правила/PPO/«серый ящик»
Г2 (устойчивость прогноза)	выполнена, но недостаточна	RMSE устойчив, замкнутый контур обрушивается
Г3 (прозрачность)	частично	бьёт NN-MPC; подтверждающий $<$ «серый ящик»
Г4а (адаптация)	не поддержана	DAgger +0,39, $p=0,088$; EKF хуже
Г4б (защита при OOD)	поддержана	защита -50% наруш., $p \approx 10^{-24}$
Г4в (без эксплуатации ошибки)	частично	подтверждающий много нарушает; защита смягчает

Таблица 3: Экономическое сопоставление в замкнутом контуре (ЕЗ, 20 повторов), по убыванию EPI. Δ EPI и p_{Holm} — парный критерий Уилкоксона против правил с поправкой Холма. Фронт = недоминируемость по (EPI $\uparrow$, шаги-нарушения $\downarrow$).

Регулятор	EPI (EUR/m ²)	Наруш., шагов	scaled pen	T-кор., %	n	Δ EPI vs прав.	p_{Holm}	Фронт
SINDy-MPC (conf+DAgger)	$5,23 \pm 2,40$	4302	426	62	20	+0,59	0,26 (нз)	•
На правилах	$4,63 \pm 0,00$	2458	485	95	20	—	—	•
SINDy-MPC (плотный)	$3,81 \pm 1,27$	6073	1206	65	20	-0,82	0,017	
МПУ «серого ящика»	$3,79 \pm 1,27$	6083	1209	65	20	-0,85	0,017	
PPO	$3,36 \pm 1,59$	1842	392	84	20	-1,28	0,001	•
SINDy-MPC (плотный+DAgger)	$3,23 \pm 2,21$	4467	624	66	20	-1,40	0,031	
Оракул (3 ч, CEM)	$1,99 \pm 0,68$	2816	379	72	20	-2,65	2e-5	
SINDy-MPC (подтверждающий)	$1,18 \pm 4,33$	5357	793	50	20	-3,46	0,009	
SAC	$-2,41 \pm 1,24$	1683	179	82	10	-7,04	0,010	•
NN-MPC	$-5,09 \pm 3,11$	4368	767	70	20	-9,72	2e-5	

Причина изолируется однопараметрической абляцией. Фиксируя библиотеку (physics_no_cross, степень 1) и МПУ, порог разреженности STLSQ λ варьируется по $[10^{-6}, 10^{-1}]$; на каждом значении для 20 повторов фиксируются число выживших коэффициентов, знаковый коэффициент котла в уравнении температуры $\Xi_{u_{\text{Boil}} \rightarrow T_{\text{in}}}$ (единственного смоделированного активного органа нагрева), *разомкнутая* ошибка многошагового прогноза температуры T_{in} на тестовом сезоне и *замкнутый* EPI (рис. 2, таблица 4).

Две величины изменяются в противоположных направлениях. С ростом λ от 10^{-6} до 0,1 модель становится экономнее (число членов $54 \rightarrow 20$), а коэффициент котла затухает и исчезает: $\Xi_{u_{\text{Boil}} \rightarrow T_{\text{in}}} \approx 0,035$ при $\lambda \leq 0,02$, 0,032 при $\lambda = 0,03$, 0,006 при $\lambda = 0,05$ и ровно 0 при $\lambda = 0,1$. Замкнутый EPI отслеживает этот обвал — с пика 4,67 при $\lambda = 0,02$ до 0,99 при $\lambda = 0,05$, ровно там, где член котла отсекается порогом. Как только в суррогате не остаётся органа нагрева, МПУ не может планировать отопление, и в отопительно-доминированную весну потеря велика. Разомкнутая метрика при этом почти инертна: ошибка многошагового прогноза изменяется лишь с 2,25 до 2,39 (на 6%), пока EPI изменяется в пять раз, а член котла исчезает вовсе. Предрегистрированный разомкнутый критерий, следовательно, нечувствителен к провалу замкнутого контура, который сам же вызывает. Это конкретный, физически читаемый пример рассогласования между точностью прогноза и качеством управления [9, 10] и реализация на разреженной идентификации

E3 Pareto (EPI × violations), 20 seeds — frontier: rule-based, SINDy-MPC(conf+Dagger), PPO




Рис. 1: Плоскость Парето (EPI × нарушения, 20 повторов). Недоминируемый фронт (красный): правила, SINDy-MPC(conf+Dagger), PPO и SAC (вырожденный угол минимума нарушений). Починенное плотное SINDy-MPC совпадает с «серым ящиком»: экономность не тождественна интерпретируемости.

Таблица 4: Слип порога разреженности λ сурrogата physics_no_cross степени 1, 20 повторов. Коэффициент котла и замкнутый EPI обрушиваются около $\lambda \approx 0,05$, тогда как разомкнутая ошибка прогноза остаётся плоской.

λ	ненулевых	$\Xi_{u_{\text{Boil}} \rightarrow T_{\text{in}}}$	RMSE (разомкн.)	EPI (замкн.)
10^{-6}	54,0	0,036	2,25	3,79
10^{-3}	49,9	0,036	2,25	3,81
0,01	41,8	0,036	2,27	4,00
0,02	38,4	0,035	2,27	4,67
0,03	34,8	0,032	2,28	3,49
0,04	30,8	0,021	2,37	1,14
0,05	27,7	0,006	2,38	0,99
0,10	20,3	0,000	2,39	2,49

того принципа идентификации для целей управления, что арбитром качества модели должен быть замкнутый контур [7, 8].

Если причина — удаление члена котла, то его восстановление должно возвращать качество; оба независимых вмешательства именно это и делают (таблица 3). Плотный рецепт (stlsq, $\lambda = 10^{-3}$) сохраняет $\Xi_{u_{\text{Boil}} \rightarrow T_{\text{in}}} \approx 0,034$ и поднимает EPI с 1,18 до 3,81; DAgger, применённый к подтверждающему рецепту, вновь вводит член через данные замкнутого контура и поднимает EPI до 5,23, неотличимо от эталона на правилах. По всем вариантам SINDy-MPC EPI монотонен относительно наличия коэффициента котла: при $\Xi_{u_{\text{Boil}} \rightarrow T_{\text{in}}} \neq 0$ он поднимается с ≈ 1 до 4–5 EUR/м². Коэффициент котла служит одномерным причинным индикатором экономической состоятельности.

Плотная починка при этом не является «чёрным ящиком»: это то же отображение «белого ящика» с




Рис. 2: Слип порога разреженности λ : замкнутый EPI (синий) обрушивается по мере обнуления коэффициента котла $u_{Boil} \rightarrow T_{in}$ (зелёный), тогда как разомкнутая ошибка прогноза (красный) остаётся плоской. Отбор модели по разомкнутому контуру нечувствителен к провалу замкнутого.

большим числом ненулевых членов, и восстановленное плотное SINDy-MPC (3,81) совпадает с первопринципным МПУ «серого ящика» (3,79) в пределах шума (рис. 1). Как только пере-разреживание устранено, интерпретируемый суррогат схлопывается в физическую модель, которую он призван был заменить. Разреженность отняла не точность и не прозрачность, а управляемость, обеспечиваемую единственным членом исполнительного механизма с малым модулем. Из этого вытекают два практических следствия. Разреженность не должна быть целью отбора модели, когда конечная задача — управление в замкнутом контуре [34, 28, 30]; а критерий прозрачности, удостоверяющий модель с обнулённым ключевым исполнительным механизмом, не полон — выпадение такого члена само по себе должно означать провал критерия.

Точность модели не объясняет провал. Если бы дело было в недостаточной точности суррогата, выигрывало бы МПУ по истинной модели. Этого не происходит: оракул даёт лишь $1,99 \pm 0,68$ EUR/m² (таблица 3), ниже эвристики, вариантов с DAgger и плотного/«серого» и PPO. Проба по горизонту (рис. 3) объясняет причину: EPI падает, а не растёт с горизонтом (+0,26 при 3 ч, +0,04 при 12 ч, −0,51 при 24 ч на 14-суточном окне, где правила дают +0,63). Прирост плода и выручка растут к уровню эвристики по мере удлинения горизонта, но затраты — главным образом на электричество и CO₂ — растут быстрее, так что оракул достигает сопоставимой продукции дороже. Это жадный перерасход из-за короткого скользящего горизонта, а не дефицит точности, поэтому рамка «разрыва до оракула» (гипотеза Г1) здесь не является осмысленным потолком. Это структурное свойство короткогоризонтного экономического МПУ, а не ошибка эксперимента: оракул корректно максимизирует ровно ту величину, которую вознаграждает симулятор, — но жадно и на слишком коротком окне.

Интерпретируемость не является узким местом. «Чёрный ящик» также не выигрывает. Эталоны




Рис. 3: Оракул не является потолком. EPI экономического МПУ по истинной модели падает с удлинением горизонта планирования и остаётся ниже эвристики на правилах (пунктир): короткий скользящий горизонт жадно перерасходует.

ОП чувствительны к нормировке: наивный РРО даёт -13 EUR/m^2 , тогда как штатная нормировка наблюдений и вознаграждения поднимает его до $+3,4$ — это урок воспроизводимости, а не свойство ОП [44]; и всё же на 20 повторях нормированный РРО (3,36) остаётся значимо ниже эвристики, а SAC нестабилен и расходится на 10 из 20 повторов. Нейросетевое же «чёрноязычное» МПУ оказывается худшим регулятором исследования ($-5,09 \text{ EUR/m}^2$), проигрывая любому интерпретируемому варианту SINDy.

Онлайн-адаптация даёт нулевой эффект. При весенних OOD-сдвигах (2021–2023, тот же сезон посадки) офлайн-суррогат уже хорошо обобщается — средний $\text{EPI} \approx 0$, опережая $-2,9$ у правил при том же сдвиге, — оставляя адаптации мало «зазора». На 60 парах (сдвиг $\times$ повтор) DAgger улучшает статический офлайн-вариант лишь на $+0,39 \text{ EUR/m}^2$ ($p = 0,088$, незначимо), а онлайн-EKF-SINDy значимо хуже ($-2,17$, $p < 10^{-6}$); прежняя меньшая выборка ($n = 9$), намекавшая на значимый выигрыш DAgger, не выдерживает большего плана. Гипотеза Г4а не поддержана. Провал под сдвигом — не постепенный дрейф коэффициентов, а проблема данных: в односезонных данных, собранных под сдвигом, факторы неразделимо смешаны (корреляция $\text{corr}(u_{\text{Vent}}, T_{\text{in}}) = +0,67$ против $+0,03$ у многолетних офлайн-данных), так что переобучение неверно выучивает эффект вентиляции. Устойчивость под OOD обеспечивают структура (сохранение члена котла) и защитный монитор, а не адаптация коэффициентов.

Безопасность и защита при выходе за пределы распределения. Доказуемая ценность прозрачного суррогата лежит в безопасности. Два его эпистемических сигнала — расстояние Махаланобиса по экзогенным входам [45, 46] и дисперсия предсказаний ансамбля [47] — коррелируют с ошибкой и прибылью (Махаланобис: $+0,63$ с ошибкой прогноза, $-0,50$ с EPI; дисперсия ансамбля: $-0,57$ с EPI), а сам сигнал служит рабочим детектором шагов с высокой ошибкой (площадь под ROC-кривой $\text{AUC} = 0,70$; рис. 4). Включение защитного монитора по сигналу Махаланобиса с откатом на регулятор правил на OOD-шагах снижает сезонные нарушения с 1723 до 863 (на 50%), одновременно улучшая EPI (с $-2,06$ до $-1,48$); снижение высокозначимо на 200 парах ($p \approx 10^{-24}$). При внесённых отказах (таблица 5, рис. 5) супервизор на невязках с тем же откатом значимо смягчает все шесть типов отказов, снижая нарушения в среднем на 1304 шага ($p \approx 6 \times 10^{-21}$, 120 пар). Это сильнейший положительный результат исследования (гипотеза Г4б).

Устойчивость ранжирования. Анализ чувствительности (рис. 6) показывает, что ранжирование опре-




Рис. 4: Генерализация и детекция OOD. Слева — замкнутый EPI по парам «обучение → тест» (зелёный — хорошо, красный — плохо). В центре — сигнал OOD (Махаланобис) коррелирует с ошибкой прогноза ($r = 0,63$). Справа — как детектор шагов с высокой ошибкой сигнал даёт AUC = 0,70.




Рис. 5: Устойчивость к отказам. Шаги-нарушения при шести внесённых отказах датчиков и механизмов без (синий) и с (оранжевый) супервизором на невязках, против бездефектного эталона (пунктир). Супервизор значительно снижает нарушения при каждом отказе.

Таблица 5: Внесение отказов: EPI и шаги-нарушения без и с супервизором; бездефектный эталон EPI 1,94, нарушения 2587. Супервизор снижает нарушения при всех шести отказах ($p \approx 6 \times 10^{-21}$ в целом).

Отказ	EPI (без)	Наруш. (без)	EPI (с)	Наруш. (с)
T_{in} залипание	0,86	4163	0,99	2055
RH смещение	-0,07	4125	0,90	2013
u_{vent} отказ	2,01	3617	2,14	2558
T_{in} смещение	1,62	3412	1,12	2165
u_{lamp} отказ	1,99	2574	2,40	1885
u_{boil} залипание	-3,18	1816	-2,16	1208

деляется ценами сильнее, чем проектными решениями: размах EPI от цены плода (19,7) и цены энергии (13,3 EUR/м²) многократно превосходит размах от неопределённости параметров растения (2,7), порога разреженности (1,3) и горизонта МПУ (0,6). Ранжирование неустойчиво к цене энергии: при дорогой энергии экономная модель «серого ящика» обгоняет энергоёмкую эвристику. Следовательно, ранжирование по одному скаляру ненадёжно, и предпочтительным является представление в виде структуры Парето.




Рис. 6: Анализ чувствительности. Размах EPI определяется ценами (плод, энергия) сильнее проектных решений (неопределённость растения, порог разреженности, горизонт); ранжирование неустойчиво к цене энергии.

5. Обсуждение

Отбор суррогата для управления. Центральный урок носит процедурный характер. Предрегистрация заморозила рецепт по разомкнутым метрикам, чтобы избежать цикличности, и тем самым выбрала модель, проваливающуюся в контуре, поскольку эта метрика нечувствительна к следствию в замкнутом контуре. Это довод не против предрегистрации, а против предрегистрации неверного критерия. Отсюда две поправки. Разреженность не должна входить в цели отбора модели для управления в замкнутом контуре: член с малым коэффициентом может быть динамически пренебрежим для прогноза, но контроль-критичен; уместны отбор, ориентированный на управление или на ценность [34, 10], проверка с включённым замкнутым контуром либо оптимизаторы, защищающие малые важные члены [30, 28]. Критерий прозрачности, в свою очередь, неполон: критерий, удостоверяющий модель, в которой обнулён единственный орган нагрева, не проверяет прозрачность в смысле, релевантном управлению; выпадение ключевого механизма, обнаружимое сверкой со структурой управления, должно означать провал критерия.

Экономность и интерпретируемость. Отрицательный результат можно было бы истолковать как «цену прозрачности», однако это неверно. Починка, возвращающая качество (восстановление члена котла), не жертвует прозрачностью: плотная модель — то же отображение «белого ящика», лишь менее экономное. Показательно, что оно совпадает с моделью «серого ящика» в пределах шума (3,81 против 3,79): как только пере-разреживание устранено, суррогат схлопывается в физическую модель, которую замещает. Разреженность разрушила не точность и не интерпретируемость, а управляемость. Оптимизация экономности во имя интерпретируемости способна незаметно сломать управление.

Сила настроенной эвристики. Сила эвристики и перерасход оракула имеют общий корень. Сезонная прибыль определяется приростом плода за дни и недели, тогда как экономическое МПУ на скользящем горизонте в несколько часов оптимизирует ближайшую прибыль и жадно урезает нагрев и CO_2 , которые окупятся бы позже. Хорошо настроенный набор правил неявно кодирует те многодневные компромиссы, которых короткогоризонтный оптимизатор не видит. Продуктивный путь к превосходству над сильными эвристиками — не лучший короткогоризонтный суррогат, а по-настоящему длиннгоризонтная экономическая постановка: терминальная функция ценности по состоянию растения либо градиентный многодневный оптимизатор; это выделяется как ключевая открытая проблема.

Обобщение и ограничения. Механизм не специфичен для тепличного дела: любой конвейер, который идентифицирует разреженный суррогат, выбирает разреженность по прогноз-ориентированным критериям и встраивает его в регулятор, подвержен тому же провалу; теплица лишь делает провал наглядным, поскольку выпавший член — именованный исполнительный механизм, чей коэффициент можно наблюдать отслеживающим прибыль. Полученные утверждения вычислительны (*in silico*) и не переносятся на физическую теплицу без отдельной валидации. Головной результат ЕЗ использует один тестовый сезон, поэтому у детерминированных регуляторов нулевая дисперсия по тестовой погоде, а приводимая дисперсия отражает лишь переидентификацию суррогата; для полной характеристики дисперсии нужно многосезонное экономическое сопоставление. Паритет с DAgger достигается ценой дополнительного бюджета данных замкнутого контура (три итерации агрегации по пять суток). Оракул — короткогоризонтный СЕМ, а не потолок. Наконец, SAC сошёлся лишь на 10 из 20 повторов и приводится как наблюдение об устойчивости, а не как настроенный конкурент.

6. Заключение

Цена интерпретируемости для МПУ на разреженной идентификации в управлении микроклиматом теплицы измерена при протоколе, спроектированном честно: экономическая прибыль из симулятора как метрика, настроенный эталон на правилах, честно нормированное ОП, равный бюджет гиперпараметров и рецепт, замороженный предрегистрацией. Предрегистрированное утверждение — что SINDy-MPC парето-конкурентоспособно при малой цене прозрачности — не подтвердилось; основной результат состоит в вскрытом механизме. Настроенная эвристика — сильный экономический эталон, и единственный интерпретируемый регулятор, дотягивающий до неё, достигает этого через починку, вызванную конкретным переносимым провалом: порог STLSQ удаляет контроль-критичный член котла, обрушивая замкнутую прибыль при неизменной разомкнутой ошибке, так что разомкнутая предрегистрированная процедура систематически удостоверяет катастрофичную для управления модель. Сравнение с дополнительными регуляторами исключает интуитивные альтернативы: оракул по истинной модели перерасходует и не является потолком, нормированный PPO улучшается, но не выигрывает, а «чёрнощичный» NN-MPC оказывается худшим. Ценность прозрачного суррогата реальна, но лежит не в EPI: защитный монитор OOD вдвое снижает нарушения, улучшая прибыль, а супервизор отказов смягчает шесть типов отказов. Экономность модели не тождественна её интерпретируемости, и разреженность не входит в число целей отбора модели, когда конечной задачей является управление в замкнутом контуре. Дальнейшая работа состоит в поиске настоящего экономического потолка — длиннгоризонтного либо терминально-ценностного регулятора, учитывающего многодневную динамику плода, — в отборе рецепта, ориентированном на управление и защищённом от ловушки разреженности, и в валидации «модель-реальность» (*sim-to-real*).

Воспроизводимость

Все эксперименты реализованы воспроизводимыми сценариями с фиксированной инициализацией. Публикуются реализации регуляторов, предрегистрированный замороженный рецепт, распределённые сценарии запуска и сборки результатов для 20 повторов и анализ, порождающий каждую таблицу и рисунок. EPI считается из модели вознаграждения симулятора, а его пошаговая экономика поэлементно поверена против цели оракула.

Список литературы

- [1] E. J. van Henten, Greenhouse climate management: an optimal control approach, Ph.D. thesis, Wageningen University (1994).
- [2] D. Q. Mayne, J. B. Rawlings, C. V. Rao, P. O. M. Scokaert, Constrained model predictive control: Stability and optimality, *Automatica* 36 (6) (2000) 789–814.
- [3] D. Lin, L. Zhang, X. Xia, Model predictive control of a Venlo-type greenhouse system considering electrical energy and water consumption, *Applied Energy* 298 (2021) 117163, vERIFY author/vol.
- [4] S. L. Brunton, J. L. Proctor, J. N. Kutz, Discovering governing equations from data by sparse identification of nonlinear dynamical systems, *Proceedings of the National Academy of Sciences* 113 (15) (2016) 3932–3937.
- [5] S. L. Brunton, J. L. Proctor, J. N. Kutz, Sparse identification of nonlinear dynamics with control (SINDYc), in: *IFAC-PapersOnLine (NOLCOS)*, Vol. 49, 2016, pp. 710–715.
- [6] E. Kaiser, J. N. Kutz, S. L. Brunton, Sparse identification of nonlinear dynamics for model predictive control in the low-data limit, *Proceedings of the Royal Society A* 474 (2219) (2018) 20180335.
- [7] M. Gevers, Towards a joint design of identification and control?, in: *Essays on Control: Perspectives in the Theory and its Applications*, Birkhäuser, 1993, pp. 111–151.
- [8] P. M. J. Van den Hof, R. J. P. Schrama, Identification and control — closed-loop issues, *Automatica* 31 (12) (1995) 1751–1770.
- [9] N. Lambert, B. Amos, O. Yadan, R. Calandra, Objective mismatch in model-based reinforcement learning, in: *Proceedings of the 2nd Conference on Learning for Dynamics and Control (L4DC)*, Vol. 120 of PMLR, 2020, pp. 761–770.
- [10] B. E. Jackson, J. H. Lee, K. Tracy, Z. Manchester, Data-efficient model learning for control with Jacobian-regularized dynamic-mode decomposition, open-loop prediction error is a poor proxy for closed-loop control – supports our thesis (2022). arXiv:2212.07885.
- [11] J. Pineau, P. Vincent-Lamarre, K. Sinha, V. Larivière, A. Beygelzimer, F. d’Alché Buc, E. Fox, H. Larochelle, Improving reproducibility in machine learning research (a report from the NeurIPS 2019 reproducibility program), *Journal of Machine Learning Research* 22 (164) (2021) 1–20.
- [12] F. Wilcoxon, Individual comparisons by ranking methods, *Biometrics Bulletin* 1 (6) (1945) 80–83.
- [13] S. Holm, A simple sequentially rejective multiple test procedure, *Scandinavian Journal of Statistics* 6 (2) (1979) 65–70.
- [14] B. Efron, R. J. Tibshirani, *An Introduction to the Bootstrap*, Chapman & Hall/CRC, 1994.
- [15] B. van Laatum, E. J. van Henten, S. Boersma, GreenLight-Gym: Reinforcement learning benchmark environment for control of greenhouse production systems, in: *IFAC-PapersOnLine*, 2025, arXiv:2410.05336; VERIFY vol/pages.
- [16] E. J. van Henten, J. Bontsema, Time-scale decomposition of an optimal control problem in greenhouse climate management, *Control Engineering Practice* 17 (1) (2009) 88–96.
- [17] W.-H. Chen, F. You, Data-driven robust model predictive control framework for greenhouse climate control, *Chemical Engineering Transactions / Control Engineering Practice* VERIFY venue/vol (2020).
- [18] S. van Mourik, B. van’t Ooster, M. Vellekoop, Plant performance in precision horticulture: Optimal climate control under stochastic uncertainty (2023). arXiv:2303.14678.
- [19] B. Morcego, W. Yin, S. Boersma, E. van Henten, V. Puig, C. Sun, Reinforcement learning versus model predictive control on greenhouse climate control, *Computers and Electronics in Agriculture* 215 (2023) 108372.
- [20] S. Mallick, F. Airaldi, A. Dabiri, C. Sun, B. De Schutter, Reinforcement learning-based model predictive control for greenhouse climate control (2024). arXiv:2409.12789.
- [21] others, Adaptive robust greenhouse climate control: Combining deep reinforcement learning and economic optimization, *Smart Agricultural Technology* VERIFY authors/vol; ScienceDirect S2772375525005581 (2025).
- [22] D. Katzin, S. van Mourik, F. Kempkes, E. J. van Henten, GreenLight – an open source model for greenhouses with supplemental lighting: Evaluation of heat requirements under LED and HPS lamps, *Biosystems Engineering* 194 (2020) 61–81.
- [23] D. Katzin, L. F. M. Marcelis, S. van Mourik, Energy savings in greenhouses by transition from high-pressure sodium to LED lighting, *Applied Energy* 281 (2021) 116019.
- [24] U. Fasel, J. N. Kutz, B. W. Brunton, S. L. Brunton, Ensemble-SINDy: Robust sparse model discovery in the low-data, high-noise limit, with active learning and control, *Proceedings of the Royal Society A* 478 (2260) (2022) 20210904.
- [25] K. Champion, P. Zheng, A. Y. Aravkin, S. L. Brunton, J. N. Kutz, A unified sparse optimization framework to learn parsimonious physics-informed models from data, *IEEE Access* 8 (2020) 169259–169271.
- [26] B. M. de Silva, K. Champion, M. Quade, J.-C. Loiseau, J. N. Kutz, S. L. Brunton, PySINDy: A Python package for the sparse identification of nonlinear dynamics from data, *Journal of Open Source Software* 5 (49) (2020) 2104.
- [27] A. A. Kaptanoglu, B. M. de Silva, U. Fasel, K. Kaheman, A. J. Goldschmidt, J. L. Callahan, C. B. Delahunt, Z. G. Nicolaou, K. Champion, J.-C. Loiseau, J. N. Kutz, S. L. Brunton, PySINDy: A comprehensive Python package for robust sparse system identification, *Journal of Open Source Software* 7 (69) (2022) 3994.
- [28] A. Cortiella, K.-C. Park, A. Doostan, Sparse identification of nonlinear dynamical systems via reweighted ℓ_1 -regularized least squares, *Computer Methods in Applied Mechanics and Engineering* 376 (2021) 113620.

- [29] N. M. Mangan, J. N. Kutz, S. L. Brunton, J. L. Proctor, Model selection for dynamical systems via sparse regression and information criteria, *Proceedings of the Royal Society A* 473 (2204) (2017) 20170009.
- [30] Z. Dang, L. Zhang, L. Wang, G. He, Balance-guided sparse identification of multiscale nonlinear PDEs with small-coefficient terms (2026). arXiv:2604.18414.
- [31] H. Hjalmarsson, M. Gevers, F. De Bruyne, J. Leblond, Identification for control: closing the loop gives more accurate controllers, in: 33rd IEEE Conference on Decision and Control (CDC), 1994.
- [32] H. Hjalmarsson, From experiment design to closed-loop control, *Automatica* 41 (3) (2005) 393–438.
- [33] R. Wei, N. Lambert, A. McDonald, A. Garcia, R. Calandra, A unified view on solving objective mismatch in model-based reinforcement learning, *Transactions on Machine Learning Research (TMLR)* arXiv:2310.06253 (2023).
- [34] A.-m. Farahmand, A. Barreto, D. Nikovski, Value-aware loss function for model-based reinforcement learning, in: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, Vol. 54 of PMLR, 2017, pp. 1486–1494.
- [35] S. Sivaranjani, Y. Shi, N. Atanasov, T. Duong, J. Feng, T. Martin, Y. Xu, V. Gupta, F. Allgöwer, Control-oriented system identification: Classical, learning, and physics-informed approaches (2025). arXiv:2512.06315.
- [36] S. Ross, G. J. Gordon, J. A. Bagnell, A reduction of imitation learning and structured prediction to no-regret online learning, in: *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics (AISTATS)*, Vol. 15 of PMLR, 2011, pp. 627–635.
- [37] W. Sun, A. Venkatraman, G. J. Gordon, B. Boots, J. A. Bagnell, Deeply AggreVaTeD: Differentiable imitation learning for sequential prediction, in: *Proceedings of the 34th International Conference on Machine Learning (ICML)*, Vol. 70 of PMLR, 2017, pp. 3309–3318.
- [38] A. Tagliabue, D.-K. Kim, M. Everett, J. P. How, Demonstration-efficient guided policy search via imitation of robust tube MPC (2021). arXiv:2109.09910.
- [39] J. Espin, D. Zhang, D. Toti, A. Pozzi, Deep-MPC: A DAgger-driven imitation learning strategy for optimal constrained battery charging (2024). arXiv:2406.15985.
- [40] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov, Proximal policy optimization algorithms (2017). arXiv:1707.06347.
- [41] T. Haarnoja, A. Zhou, P. Abbeel, S. Levine, Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor, in: *Proceedings of the 35th International Conference on Machine Learning (ICML)*, Vol. 80 of PMLR, 2018, pp. 1861–1870.
- [42] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, N. Dormann, Stable-baselines3: Reliable reinforcement learning implementations, *Journal of Machine Learning Research* 22 (268) (2021) 1–8.
- [43] J. Demšar, Statistical comparisons of classifiers over multiple data sets, *Journal of Machine Learning Research* 7 (2006) 1–30.
- [44] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, D. Meger, Deep reinforcement learning that matters, in: *Proceedings of the 32nd AAAI Conference on Artificial Intelligence*, 2018.
- [45] P. C. Mahalanobis, On the generalised distance in statistics, *Proceedings of the National Institute of Sciences of India* 2 (1) (1936) 49–55.
- [46] K. Lee, K. Lee, H. Lee, J. Shin, A simple unified framework for detecting out-of-distribution samples and adversarial attacks, in: *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 31, 2018.
- [47] B. Lakshminarayanan, A. Pritzel, C. Blundell, Simple and scalable predictive uncertainty estimation using deep ensembles, in: *Advances in Neural Information Processing Systems (NeurIPS)*, Vol. 30, 2017.